

Głębokie sieci neuronowe. Zestaw stosowy auto-encoderów odszumiających (ang. stacked denoising autoencoders) uczony do problemu klasyfikacji na zbiorze cyfr pisanych odręcznie (MNIST). Wpływ wyboru zbioru uczącego fazy pretreningu na rezultaty klasyfikacji.

Szymon Bugaj
promotor: prof. Andrzej Pacut

Politechnika Warszawska, Wydział Elektroniki i Technik Informacyjnych

s.bugaj@mion.elka.pw.edu.pl

13 lipca 2015

Wyodrębnić należy 4 zbiory danych, wykorzystane w procesie uczenia i testowania zestawu stosowego auto-encoderów odszumiających:

- zbiór uczący fazy pretreningu,
- zbiór uczący fazy dostrajania (musi być etykietowany),
- zbiór walidacyjny fazy dostrajania (musi być etykietowany),
- zbiór testowy (musi być etykietowany).

Warianty fazy pretreningu

W testach uwzględnione zostały następujące warianty składu zbioru uczącego fazy pretreningu:

- pretrening na zbiorze uczącym fazy dostrajania (50 000 cyfr z MNIST),
- pretrening na zbiorze uczącym fazy dostrajania (50 000 cyfr z MNIST + 120 000 liter z NIST, czyli 170 000 przykładów),
- pretrening wyłącznie na zbiorze liter (50 000 liter z NIST).

Zbiór danych (litera + cyfry)



Zestaw stosowy auto-encoderów odszumiających (ang. stacked denoising autoencoders)

- faza pretreningu (ang. pretraining)
 - podejście zachłanne, niezależnie dla każdej warstwy,
 - zbiór wejściowy dla auto-encodera trenującego i warstwę ukrytą stanowiło wyjście z $i - 1$ warstwy ukrytej, dla której faza pretreningu już się odbyła,
 - każda warstwa uczona jest przez 15 epok
- faza strojenia (ang. fine-tuning) - standardowe uczenie
 - zakończone, gdy brak polepszenie najlepszego wyniku na zbiorze walidacyjnym przez 10 epok

Model z najlepszym wynikiem walidacyjnym testowany jest na zbiorze testowym.

Metoda doboru początkowych parametrów sieci

- wyrazy wolne - przypisanie 0
- wagi połączeń pomiędzy neuronami:

$$(-\sqrt{6/(N_{h^{k-1}} + N_{h^k})}, \sqrt{6/(N_{h^{k-1}} + N_{h^k})})$$

Auto-encoder odszumiający

- architektura

$$h(x) = \text{sigmoid}(\tilde{x} * W + b) \quad (1)$$

$$\hat{x}(x) = \text{sigmoid}(h(x) * W^T + c) \quad (2)$$

- uczenie, metoda stochastycznego spadku gradientu

$$\Delta = -\nabla_{\theta} l(f(x^i); \theta), x^i)$$

$$\theta \leftarrow \theta + 0.01\Delta$$

- funkcja kary (suma entropii krzyżowych Bernoulliego, ang. sum of Bernoulli cross-entropies)

$$l(f(x)) = -\sum_k (x_k \log(\hat{x}_k) + (1 - x_k) \log(1 - \hat{x}_k))$$

Auto-encoder odszumiający

- zaszumienie zbioru wejściowego

```
foreach  $i$  in  $N_x$  do  
  | foreach  $d$  in  $N_{Dim}$  do  
  | | if random_binomial (corrupt) then  
  | | |  $\tilde{x}_d^i = 0$ ;  
  | | | else  
  | | | |  $\tilde{x}_d^i = x_d^i$   
  | | | end  
  | end  
end
```


Faza dostrajania

- architektura
 - warstwy ukryte

$$h^{k+1}(x) = \text{sigmoid}(h^k(x) * W^k + b^k)$$

- warstwa wyjściowa

$$h^{L+1}(x) = \text{softmax}(h^L(x) * W^L + b^L)$$

- uczenie, metoda stochastycznego spadku gradientu

$$\Delta = -\nabla_{\theta} l(f(x^i); \theta), f^i)$$

$$\theta \leftarrow \theta + 0.01\Delta$$

- funkcja kary







$$l(f(x^i), y^i) = -\log f(x^i)_{y^i}$$

Wpływ składu zbioru uczącego fazy pretreningu na jakość klasyfikacji

Liczba cyfr	Liczba liter	<i>avg</i>	<i>std</i>	<i>min</i>	$t_{avg}[m]$
0	0	1.86%	0.06%	1.77%	47
50k	0	1.55%	0.05%	1.48%	66
0	50k	1.58%	0.08%	1.41%	65
50k	120k	1.59%	0.045%	1.56%	132

Tabela: Jakość klasyfikacji i czasy uczenia dla zestawu stosowego auto-encoderów odsumiających z trzema warstwami ukrytymi 784 – 500 – 500 – 500 – 10. Dla każdego wariantu wykonano 10 uruchomień. Implementację stworzona z wykorzystaniem biblioteki Theano i uruchomiono na czterordzeniowym CPU Intel Core i7.

Bibliografia

-  Bengio, P. Lamblin, D. Popovici and H. Larochelle, Greedy Layer-Wise Training of Deep Networks, in Advances in Neural Information Processing Systems 19 (NIPS'06), pages 153-160, MIT Press 2007.
-  Vincent, H. Larochelle Y. Bengio and P.A. Manzagol, Extracting and Composing Robust Features with Denoising Autoencoders, Proceedings of the Twenty-fifth International Conference on Machine Learning (ICML'08), pages 1096 - 1103, ACM, 2008.
-  Hugo Larochelle <http://info.usherbrooke.ca/hlarochelle/>
-  The MNIST database of handwritten digits, Yann LeCun, Corinna Cortes, Christopher J.C. Burges, <http://yann.lecun.com/exdb/mnist/>
-  Biblioteka Theano, <http://deeplearning.net/software/theano/>
-  NVIDIA® cuDNN – GPU Accelerated Deep Learning library, <https://developer.nvidia.com/cuDNN>